pandas习题

> 补上没有做完的习题😅

```
#EX1 2(c)
tt=[]
tt=[(i,j) for i in t1 for j in t2]
tt1=pd.Series(tt)
tt2=tt1.values.reshape(-1,1)
#如何删除tt2中重复的组合呢？
h1=h[["Type 1","Type 2"]].drop_duplicates()
#如何从tt2中减去h1呢？
```

```
#EX1 3(a)
def ch(a):
 b=[]
 for i in a:
     if i >120:
         b.append("high")
     elif i <50:
         b.append("low")
     else:
         b.append("mid")
 return b
pd.Series(ch(h["Attack"]))
```

上面这道题一直在纠结如何使用`mask`,`where`,`clip`函数，最终还是使用了老方法😂😂

```
#3（b）
m=h["Type 1"]
n=[]
for i in m.values:
n.append(i.upper())
n
pd.Series(n)
```

```
#3(c)
h2=h1.median(axis=1)
h3=abs(h1.values-h2.values.reshape(-1,1))
d=[]
for i, j in zip(h1.values,h3.argmax(axis=1)):
 d.append(i[j])
df=pd.Series(d).sort_values()
df
```

```
#EX2 1
#尚需时间
```

正式进入今天的任务~

尚需多次思考	需要解决	注意事项
🤔	🚑	⚠

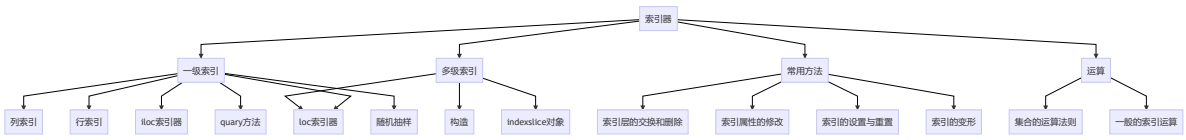

一级索引

1. DataFrame及Series的列索引

类型		返回值
单个	df['Name']	series
多个	df[["Name"，'Gender']]	dataframe

2. Series的行索引

索引	单个	多个	切片
字符串	s["a"]	s[["a",'"b"]]	s["c":"b",-2]
整数	s[1]	s[[1,2]]	s[1,-1,2]
	索引元素	索引元素	索引位置 **整数切片和字符串切片不一样的地方**

3. DataFrame的行索引

	loc索引器	iloc索引器
基于	元素	位置
形式	loc[*,*]	iloc[*,*]

- **loc索引器**
  - 单个元素
    - [行]👉取👉Series（一行）或 DataFrame（多行）

```
b.loc["Qiang Sun"]
    School  Grade   Gender  Height  Weight  Transfer    Test_Number
Test_Date   Time_Record
Name
Qiang Sun   Tsinghua University Junior  Female  163.1   53.0    N
1   2019/12/11  0:05:08
Qiang Sun   Tsinghua University Sophomore   Female  154.3   40.0
N   1   2019/12/30  0:04:37
Qiang Sun   Shanghai Jiao Tong University   Junior  Female  160.8
NaN N   1   2019/9/7
# 返回DataFrame

b.loc["Quan Zhao"]
School          Shanghai Jiao Tong University
Grade                                  Junior
Gender                                 Female
Height                                  160.6
Weight                                     53
Transfer                                    N
Test_Number                                 2
Test_Date                            2019/10/4
Time_Record                           0:03:45
Name: Quan Zhao, dtype: object
# 返回Series
```

    - [行,列]👉取👉唯一值（一行）或 Series（多行）
  - 元素列表
    - [多行，多列]

```
b.loc[["Mei Sun","Quan Zhao"],["School","Gender"]]

School  Gender
Name
Mei Sun Shanghai Jiao Tong University   Male
Mei Sun Shanghai Jiao Tong University   Female
Quan Zhao   Shanghai Jiao Tong University   Female
```

- 切片
  - [行1:行3,列1:列3]

```
b.loc[:Quan Zhao","School":"Gender"]
```

> ⚠ DataFrame使用整数索引时，整数切片的要求和字符串的要求一样，都是**元素**切片，包含端点且起点、终点不允许有重复值

不是说需要用到slice()方法吗

是在表示lambda函数时，使用slice(a,b)

- 布尔运算
  - [condition]
    - 单一条件

```
b.loc[b["Weight"]>70]
b.loc[b["Grade"].isin(["Freshman","Senior"])]#多多理解
```

    - 复合条件

```
b.loc[b["Weight"]>70 & b["Grade"]=="Senior"]
```

> 这个语句一直显示出错，原因在哪里?
>
> 目测是因为逻辑运算顺序的原因

```
b.loc[(b["Weight"]>70) & (b["Grade"]=="Senior")]
#改成这样就好了
c1=b.School=="Fudan University"
c2=b.Weight>70
b.loc[c1&c2]
```

> **练一练**
>
> 利用布尔运算筛选出数据集类型为数值的列
>
> ```
> b.loc[(b.dtypes==float64)|(b.dtypes==int64)]
> ```
>
> 不知道如何表示 数值型数据，float64

- 函数

相当于将布尔运算、切片、多元素等用函数混合起来作为统一条件

  - lambda表达式

```
b.loc[lambda x:"Quan Zhao",lambda x:"Gender"]
```

前一个匿名函数代表行，后一个代表列

- slice 切片

```
b.loc[lambda x:slice("Gaojuan You","Gaoqiang Qian")]
#对不支持切片的字符型变量使用`slice()`包装

#做对比
b.loc[:Quan Zhao","School":"Gender"]
```

- 🤔 使用b.loc方法进行赋值

```
b.loc[lambda x:"Quan Zhao",lambda x:"Gender"]="male"
```

- **iloc索引器**
  - 和loc索引器差不多
    - ```
      b.iloc[lambda x:slice(3,6),lambda x:slice(3,6)]
      ```
  - 布尔运算
    - ```
      b.iloc[(b.Weight>80).values]
      ```

      使用布尔运算还需要绕一绕，en，不如loc大法好

4. Quary方法

原理
quary帮用户注册了所有来自DataFrame的列名，不需要重复使用DataFrame的名字
过程

应用
⚠单双引号混合使用，避免报错
⚠==是等于，=是赋值，不要再忘记啦
⚠含有空格的列名，使用`col name ,两个!
⚠注意逻辑运算符运算规则

```
b.query("Weight>80")
b.query('(Weight>80) & (Grade=="Senior")')
b.query('(Weight>80) & (Grade=="Senior") & (School=="Fudan University")')
```

字符串与列表的比较		
类型	等价于	作用
==	is in	元素出现在列表中
!=	not in	元素没有出现在列表中

引用外部变量
zai外部变量前加@

```
low,high=50,100
b.query('Weight.between(@low,@high)')
```

5. 随机抽样

b.sample()	n	axis	frac	replace	weights
	数量	0 行 1 列	抽样比例	是否放回	加权

```
b.query('Weight>80').sample(5,axis=0,weights=[1,2,3,4,5,6,7,8])
```

多级索引

> Q：多级索引和索引器的区别在哪里？
>
> 多层索引中元素为元组

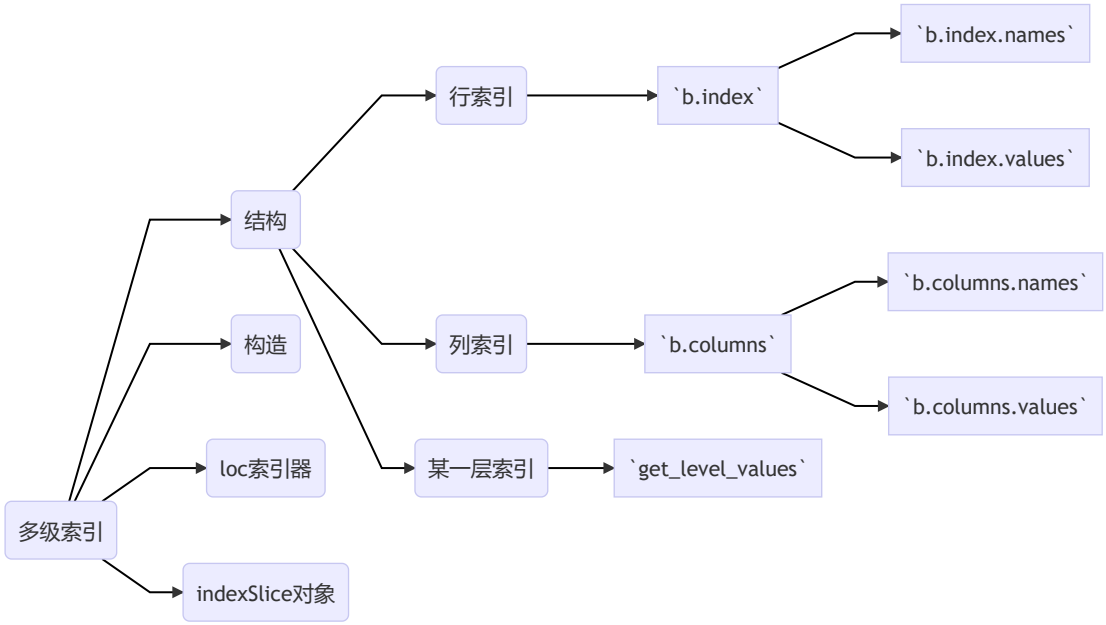

1. **结构**

index	columns		某一层	
index.names	columns.names	列名/行名	get_level_values	index.get_level_values(0)
index.values	columns.values	列值/行值		columns.get_level_values("Height")

2. **构造**

构造方法1

`from_tuples(list(tuple),names)`

```
my_tuple=[("a","cat"),("a","dog"),("b","cat"),("b","dog")]
pd.MultiIndex.from_tuples(my_tuple,names=["First","Second"])
```

在**索引**的时候会提到一些元组特殊的用法

构造方法2

`from_arrays(list(list),names)`

```
my_array=[list("aabb"),["cat","dog"]*2]
pd.MultiIndex.from_arrays(my_array,names=["First","Second"])
```

构造方法3

`from_products(list(list),names)`

```
pd.MultiIndex.from_product([["a","b"],["cat","dog"]],names=
["First","Second"])
MultiIndex([('a', 'cat'),
            ('a', 'dog'),
            ('b', 'cat'),
            ('b', 'dog')],
           names=['First', 'Second'])
```

对于有规律的重复，方法3最有效，其次是方法2

> **练一练**
>
> 构造行索引名分别为"School","Gender"，列索引名为“Indicator”,“Grade"
>
> "School"值为A，B　　”Gender“值为Female，Male
>
> ”Indicator“值为Height，Weight　　”Grade“值为Fresh，Senior
>
> ```
> c=pd.MultiIndex.from_product([["Height","Weight"],
> ["Fresh","Senior"]],names=["Indicator","Grade"])
> r=pd.MultiIndex.from_product([["A","B"],["Female","Male"]],names=
> ["School",'Gender'])
> df=pd.DataFrame((np.random.randn(4,4)*5).tolist(),index=r,columns=c)
> ```

	Indicator	Height		Weight	
	Grade	Fresh	Senior	Fresh	Senior
School	Gender				
A	Female	-2.100728	-2.389388	2.317410	-3.994160
	Male	4.659858	-2.298349	-12.202953	-3.790735
B	Female	-2.355293	1.040737	8.526992	0.637517
	Male	-1.318188	4.388309	2.139527	-1.911993

	Big			D			E			F
	Small	d	e	f	d	e	f	d	e	f
Upper	Lower									
A	a	0.220960	0.167448	0.204048	0.567983	0.041257	0.314705	0.273691	0.048042	0.717436
	b	0.797301	0.231192	0.227005	0.157571	0.035430	0.386273	0.262699	0.488681	0.902136
	c	0.340054	0.847901	0.071511	0.605251	0.394836	0.813149	0.354943	0.030084	0.866201
B	a	0.460495	0.375446	0.568611	0.566061	0.385672	0.294243	0.917090	0.009898	0.624617
	b	0.680753	0.465111	0.000910	0.491011	0.550612	0.348545	0.700561	0.393256	0.464524
	c	0.305332	0.810764	0.396191	0.212443	0.631912	0.285481	0.542446	0.886548	0.101798
C	a	0.663625	0.273231	0.601443	0.589559	0.941332	0.910266	0.168471	0.880803	0.723939
	b	0.515569	0.529788	0.151494	0.152447	0.217226	0.209966	0.270863	0.340292	0.826405
	c	0.551500	0.673296	0.908733	0.587909	0.746446	0.273996	0.186807	0.558689	0.497656

3. 索引器

⚠多级索引中元素以**元组**为单位

- 筛选A、Female的同学

```
dfi=df.sort_index()
dfi.loc[("A","Female")]#筛选A校女性名单
```

> **练一练**
>
> 去除重复索引后进行元素切片

- 关于元组的特殊用法

对多层的元素进行交叉组合后索引，需要指定loc的列，全选用:表示。

每一层需要选中的元素用列表存放，传入loc的形式为`[(list1,list2),cols]`

```
df.loc[(["A"],["Female"]),:]

#比较两者的区别
df.loc[[("Peking University","Junior"),("Fudan University","Sophomore")]]
df.loc[(["Peking University","Fudan University"],["Junior","Sophomore"]),:]
```

🤔还需要好好想想

4.IndexSlice对象

- 解决以下问题:

☒ 对每层进行切片

☒ 混合使用切片和布尔运算

- 形式

形式	loc[idx[*,*]]	loc[idx[*,*],idx[*,*]]
	`df_s.loc[idx["C":,("D","f"):]]`	`df_s.loc[idx[:"A","b":],index["E":,"e":]]`
	每个元素是一个元组	

```
index=IndexSlice
```

索引的常用方法

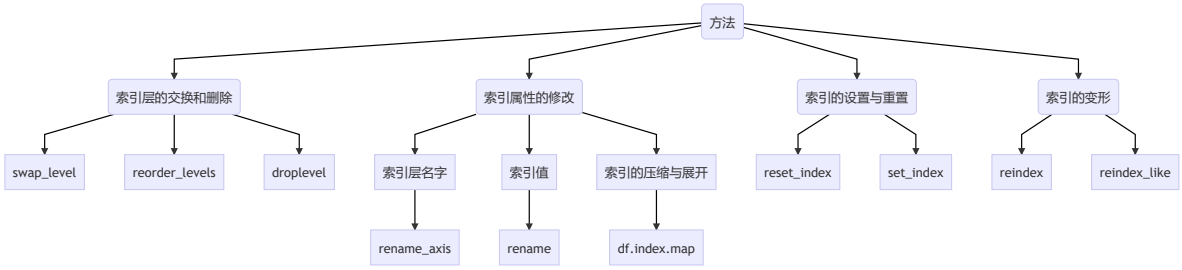

1.索引层的交换和删除

```
L1,L2 = ['A','B','C'],['a','b','c']
mul_index1 = pd.MultiIndex.from_product([L1,L2],names=('Upper', 'Lower'))
L3,L4 = ['D','E','F'],['d','e','f']
mul_index2 = pd.MultiIndex.from_product([L3,L4],names=('Big', 'Small'))
df_s = pd.DataFrame(np.random.rand(9,9),index=mul_index1,columns=mul_index2)

df_s.reorder_levels([1,0],axis=1)
df_s.swaplevel(0,1,axis=1)
```

索引层内部交换可以使用`swaplevel()`以及`reorder_levels()`，前者适用两者，后者适用两者及以上

```
df_s.droplevel(1,axis=1)
df_s.droplevel([0,1],axis=1)
```

`droplevel()`删除某个/某些索引层

⚠以上两种方法都不会改变原数据

2.索引属性的修改

- 对索引层**名字**的修改

	Big			D			E			F
	Small	d	e	f	d	e	f	d	e	f
Upper	Lower									
A	a	0.220960	0.167448	0.204048	0.567983	0.041257	0.314705	0.273691	0.048042	0.717436
	b	0.797301	0.231192	0.227005	0.157571	0.035430	0.386273	0.262699	0.488681	0.902136
	c	0.340054	0.847901	0.071511	0.605251	0.394836	0.813149	0.354943	0.030084	0.866201
B	a	0.460495	0.375446	0.568611	0.566061	0.385672	0.294243	0.917090	0.009898	0.624617
	b	0.680753	0.465111	0.000910	0.491011	0.550612	0.348545	0.700561	0.393256	0.464524
	c	0.305332	0.810764	0.396191	0.212443	0.631912	0.285481	0.542446	0.886548	0.101798
C	a	0.663625	0.273231	0.601443	0.589559	0.941332	0.910266	0.168471	0.880803	0.723939
	b	0.515569	0.529788	0.151494	0.152447	0.217226	0.209966	0.270863	0.340292	0.826405
	c	0.551500	0.673296	0.908733	0.587909	0.746446	0.273996	0.186807	0.558689	0.497656

```
#upper、lower分别变为yeah、no    big变为large
df_s.rename_axis(index={"Upper":"yeah","Lower":"No"},columns={"Big":"large"})
```

- 对索引**值**的修改

```
#用数字代替字母
df_s.rename(index={"a":1,"b":2,"c":3},columns={"D":4,"E":5,"F":6},level=0)
#效果：只做成了一半
```

只能设置 行列相同的 索引层level 吗？行列不一样时，Level应该如何表示？

- 替换整个索引**元素**

```
a=iter(list("123456789"))
df_s.rename(index=lambda x:next(a),level=1)
```

🕵next（a）起的作用是什么呢?

- 多级索引的**压缩**与**展开**（A-a）

除了`droplevel`，这里可以**改变索引层数量**

```
#压缩
df_s.index=df_s.index.map(lambda x:x[0]+'-'+x[1])
df_s
#展开
df_S.index.map(lambda x:tuple(x.split("-")))
#我可能会忘了tuple函数
```

`map`方法是定义在`index`上，只能应用在行上

3.索引的设置与重置

同样，改变**索引数量**

```
df_s.reset_index("Upper",drop=True)#append=True 表示丢弃Upper索引
df_s.droplevel("Upper")
#两者效果一样

df_s.reset_index("Upper").set_index("Upper",append=True)
#append=True 表示添加新索引，False表示代替
```

4.索引的变形

和`rename_axis`单纯改变索引名字不一样，`reindex`可以____

`reindex_like`相当于格式刷

🕵应用在多重索引上呢?

索引运算

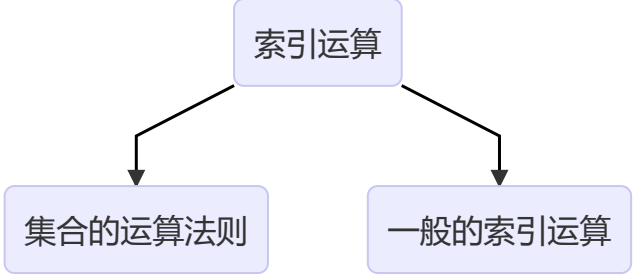

1.集合的运算法则

交集	并集	补集	S1-S2
S1.interaction(S2)	S1.union(S2)	S1.symmetric_difference(S2)	S1.difference(S2)
S1 & S2	S1 | S2	S1 ^ S2	(S1 ^ S2) & S1

Q: 两张表需要做集合运算的列没有设置索引

```
S1[S1.id.isin(S2)]
```

🤔思考思考

练习

1. ```
   dt=pd.read.csv("company.csv")
   ```

```
<bound method NDFrame.head of       EmployeeID birthdate_key  age         city_name
department  \
0           1318      1/3/1954   61         Vancouver         Executive
1           1319      1/3/1957   58         Vancouver         Executive
2           1320      1/2/1955   60         Vancouver         Executive
3           1321      1/2/1959   56         Vancouver         Executive
4           1322      1/9/1958   57         Vancouver         Executive
...          ...           ...  ...               ...               ...
6279        8036      8/9/1992   23  New Westminister  Customer Service
6280        8181     9/26/1993   22     Prince George  Customer Service
6281        8223     2/11/1994   21             Trail  Customer Service
6282        8226     2/16/1994   21          Victoria  Customer Service
6283        8264     6/13/1994   21         Vancouver  Customer Service

               job_title gender
0                    CEO      M
1              VP Stores      F
2          Legal Counsel      F
3     VP Human Resources      M
4              VP Finance      M
...                   ...    ...
6279             Cashier      F
6280             Cashier      M
6281             Cashier      M
6282             Cashier      F
6283             Cashier      F

[6284 rows x 7 columns]>
```

- 分别只使用 `query` 和 `loc` 选出年龄不超过四十岁且工作部门为 `Dairy` 或 `Bakery` 的男性。

```
dt.loc[(dt.age<40)&dt.department.isin(["Dairy","Bakery"])&(dt.gender=="M")]
dt.query('age<40 & department.isin(["Dairy","Bakery"])& (gender=="M")')
```

- 选出员工 `ID` 号 为奇数所在行的第1、第3和倒数第2列。

  ```
  dt.loc[dt.EmployeeID/2!=0,["EmployeeID","age","job_title"]]
  ```

  按照以下步骤进行索引操作：
  ```

- 把后三列设为索引后交换内外两层

```
dt.set_index(["city_name","job_title","gender"]).swaplevel(0,2,axis=0)
```

- 恢复中间一层

```
dt.reset_index("job_title")
```

- 修改外层索引名为 `Gender`

```
dt.rename_axis(index={"gender":"Gender"})
```

- 用下划线合并两层行索引

```
dt.index=dt.index.map(lambda x:(x[0]+"_"+x[1]))
```

- 把行索引拆分为原状态

```
dt.index=dt.index.map(lambda x:tuple(x.split("_")))
#报错!
```

- 修改索引名为原表名称

```
dt.reset_index()
```

- 恢复默认索引并将列保持为原表的相对位置

```
#更换列变量
```

2.
```
tn=pd.read_csv('chocolate.csv')
```

- 把列索引名中的 `\n` 替换为空格。
- 巧克力 `Rating` 评分为1至5，每0.25分一档，请选出2.75分及以下且可可含量 `Cocoa Percent` 高于中位数的样本。
- 将 `Review Date` 和 `Company Location` 设为索引后，选出 `Review Date` 在2012年之后且 `Company Location` 不属于 `France, Canada, Amsterdam, Belgium` 的样本。

参考文章

1. https://cloud.tencent.com/developer/article/1638534
2. joyfulpandas by DataWhale